生成AIの仕組み

なぜ文章が書けるのか

A-102 | 全社員向け入門 | 20分

今日のゴール

1. LLMの基本原理を平易に説明できる
2. AIが学習データからパターンを学ぶ仕組みを理解する
3. 生成AIの「できること」と「仕組み上の限界」を区別できる

CORE CONCEPT

生成AIは何をしている?

「次に来る言葉を予測する」を繰り返しているだけ

今日の天気は -> 晴れ -> です -> 。

スマホの予測変換の超高性能版

「考えている」のではなく、統計的に最もありそうな言葉を選んでいる

KEY TERM

LLM -- 大規模言語モデルの全体像

L = Large（大規模）

数兆語のテキストを学習

L = Language（言語）

言葉のパターンを扱う

M = Model（モデル）

パターンを数式で表現

「世界中の図書館の本を読んだ人」のようなもの。ただし「理解」ではなくパターン記憶。

STEP 1

学習ステップ1: 大量のテキストを読み込む

13兆+	数百万冊	約90%
トークン（GPT-4推定）	書籍相当のテキスト量	英語データの比率

- Web / ニュース
- 書籍 / 論文
- GitHub コード
- SNS / フォーラム

データの質がAIの質を決める。偏り・誤情報も一緒に学習してしまう。

STEP 2

学習ステップ2: 穴埋め問題を解いて学ぶ

「今日は天気が ____ ので公園に行った」 -> 「よい」を予測

1. **最初はデタラメな回答** — ランダムに近い予測からスタート
2. **正解と比較して修正** — 誤差を計算し、パラメータを微調整
3. **何兆回も繰り返す** — だんだん正確な予測ができるように

パラメータ（調整つまみ）: GPT-4は推定1.8兆個。最適値を見つける作業が「学習」

STEP 3 / RLHF

学習ステップ3: 人間のフィードバックで磨く

AIが複数回答を生成

同じ質問に対して
複数パターンを出力

人間が比較・評価

「こちらが正確で丁寧」
と順位をつける

報酬で調整

良い回答パターンを
強化する

結果: 「次の言葉を予測」だけでなく「人間に役立つ回答」を生成する方向に進化

INFERENCE

推論の仕組み -- 確率的に次の単語を選ぶ

入力: 「日本の首都は」

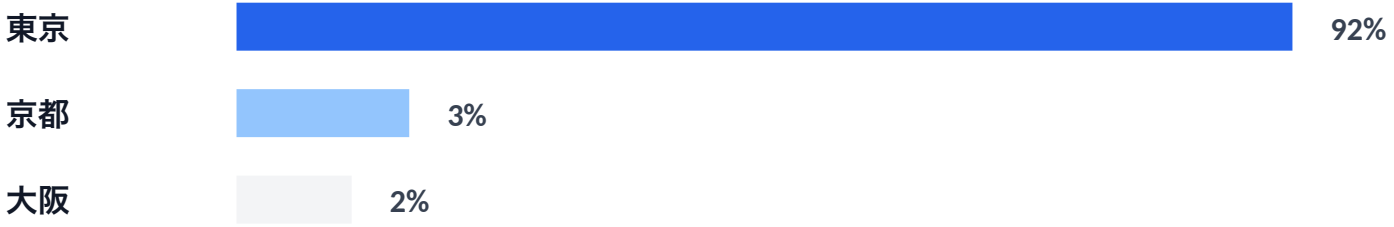

Temperature 低い: 確実な回答（事実確認向き）

Temperature 高い: 創造的な回答（ブレスト向き）

ARCHITECTURE

Transformer -- なぜ高性能なのか

核心: アテンション（注意機構） -- 文中の単語間の関連度を計算

「銀行に行った。お金を下ろす。」

銀行 + お金 -> 金融機関

「銀行に行った。魚を釣る。」

銀行 + 釣り -> 川の土手

2017年 Google 「Attention Is All You Need」以降、全主要モデルが採用

STRENGTHS

生成AIが得意なこと

文章作成・要約・翻訳

メール下書き、報告書、多言語翻訳

アイデアの壁打ち

企画ブレスト、多角的な提案

情報の整理・構造化

議事録整理、分類、表形式変換

コード生成・説明

プログラム作成、既存コード解説

共通点: 「既存パターンの組み合わせ」で対応できるタスク

LIMITATION

生成AIの限界1: ハルシネーション

事実でない情報をもっともらしく生成してしまう現象

なぜ起きるのか?

- AIは「事実かどうか」を確認する機能を持たない
- 「次に来そうな言葉」を選んでいるだけ
- パターンに従って自然な文を作るが、事実性は無関係

実例: 米国の弁護士がChatGPTで判例調査 -> 架空の判例を6件引用し裁判所で問題に

LIMITATIONS

生成AIの限界2: 最新情報・計算・倫理判断

最新情報を知らない

学習データの締め切り以降の出来事は未知

計算が苦手

電卓ではなく言葉の予測エンジン。桁数増で誤り増

倫理判断ができない

善悪の価値判断は本質的に不可能。パターンに過ぎない

全て「次の言葉を予測する」仕組みから来る構造的な限界

PRACTICE

仕組みを知ると使い方が変わる

Before

AIを万能ツールとして使う

ハルシネーションに振り回される

After

得意分野に絞って使う

高い成果を安定的に出せる

下書き利用

AIの出力は必ず人間が編集・確認

ファクトチェック

数字・日付・人名は一次情報で裏取り

壁打ち活用

アイデア発散・論点整理に最適

COMPARISON

主要モデルの比較

モデル	開発元	特徴	公開形態
GPT-4	OpenAI	マルチモーダル、最も広く利用	API / 有料
Claude	Anthropic	安全性重視、長文処理が得意	API / 有料
Gemini	Google	検索・Gmail統合、最新情報対応	API / 無料有
Llama	Meta	オープンソース、自社運用可能	無料公開

根本は同じTransformerベース。学習データとRLHFの方針で「味付け」が異なる

まとめ

1. 生成AIの正体は「次の単語を予測する」仕組み
2. 大量データからパターンを学習し、RLHFで磨かれる
3. 得意分野で活用し、限界を理解して使いこなす

確認テストに挑戦 -> 5問中4問正解で修了

お疲れさまでした

確認テストに進みましょう